

# Estimador de Máxima Verossimilhança de $g(\mu) = P_\mu(X > 0)$ e sua Distribuição Assintótica

## 1. Enunciado

Sejam  $X_1, X_2, \dots, X_n \sim \mathcal{N}(\mu, 1)$  i.i.d.

Queremos:

- Obter o estimador de máxima verossimilhança (EMV) de:

$$g(\mu) = P_\mu(X > 0).$$

- Determinar a distribuição aproximada do EMV de  $g(\mu)$  quando  $n$  é grande.

## Solução

### Passo 1: Expressar $g(\mu)$

Como  $X \sim \mathcal{N}(\mu, 1)$ , temos que:

$$g(\mu) = P_\mu(X > 0) = \int_0^\infty \frac{1}{\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2}} dx.$$

Fazendo a mudança de variável  $Z = X - \mu \sim \mathcal{N}(0, 1)$ , obtemos:

$$g(\mu) = P(Z > -\mu) = \Phi(\mu),$$

onde  $\Phi$  é a função de distribuição acumulada da normal padrão.

**Conclusão:**

$$g(\mu) = \Phi(\mu).$$

### Passo 2: EMV de $\mu$

A função de verossimilhança da amostra  $X_1, \dots, X_n$  é:

$$L(\mu) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} e^{-\frac{(X_i - \mu)^2}{2}} = (2\pi)^{-\frac{n}{2}} \exp\left(-\frac{1}{2} \sum_{i=1}^n (X_i - \mu)^2\right).$$

Maximizando em relação a  $\mu$ , encontramos o EMV:

$$\hat{\mu}_{\text{EMV}} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

### Passo 3: EMV de $g(\mu)$

Sabemos que  $g(\mu) = \Phi(\mu)$ , portanto o estimador de máxima verossimilhança de  $g(\mu)$  é:

$$\hat{g}_{\text{EMV}} = g(\hat{\mu}_{\text{EMV}}) = \Phi(\bar{X}).$$

### Passo 4: Distribuição assintótica de $\hat{g}$ (método delta)

Sabemos que

$$\bar{X} \sim \mathcal{N}\left(\mu, \frac{1}{n}\right).$$

Como  $\hat{g} = \Phi(\bar{X})$ , aplicamos o método delta para encontrar a distribuição assintótica de  $\hat{g}$ .

#### Passo 4.1: Derivada de $g(\mu)$

A derivada da função  $g$  é a densidade da normal padrão:

$$g'(\mu) = \phi(\mu) = \frac{1}{\sqrt{2\pi}} e^{-\frac{\mu^2}{2}}.$$

#### Passo 4.2: Aplicar o método delta

A variância aproximada de  $\hat{g}$  é dada por:

$$\text{Var}(\hat{g}) \approx [g'(\mu)]^2 \text{Var}(\bar{X}) = \phi(\mu)^2 \cdot \frac{1}{n}.$$

Portanto, para  $n$  grande, temos:

$$\hat{g}_{\text{EMV}} = \Phi(\bar{X}) \approx \mathcal{N}\left(\Phi(\mu), \frac{\phi(\mu)^2}{n}\right).$$

## Resumo final

- Parâmetro de interesse:

$$g(\mu) = P_{\mu}(X > 0) = \Phi(\mu).$$

- Estimador de máxima verossimilhança:

$$\hat{g} = \Phi(\bar{X}).$$

- Distribuição assintótica para  $n \rightarrow \infty$ :

$$\hat{g} \approx \mathcal{N}\left(\Phi(\mu), \frac{\phi(\mu)^2}{n}\right).$$

## 2. Simulação no R

Simulamos uma amostra com  $n = 100$ ,  $\mu = 1.5$ , e variância 1.

```
set.seed(123)

n <- 100
mu_true <- 1.5
x <- rnorm(n, mean = mu_true, sd = 1)

x_bar <- mean(x)
g_hat <- pnorm(x_bar)
g_hat # estimativa de  $P(X > 0)$ 
```

## 3. Estimando a variância de $\hat{g} = \Phi(\bar{X})$ com `deltamethod()`

Sabemos que  $\bar{X} \sim \mathcal{N}(\mu, 1/n)$ . Usamos o método delta para aproximar:

$$\text{Var}(\Phi(\bar{X})) \approx [\phi(\mu)]^2 \cdot \frac{1}{n}$$

onde  $\phi(\mu) = \frac{1}{\sqrt{2\pi}}e^{-\mu^2/2}$  é a densidade da normal padrão.

No R, fazemos:

```
install.packages("msm")
library(msm)

var_mu_hat <- 1 / n
deltamethod("pnorm(x1)", mean = x_bar, cov = var_mu_hat)
```

## 4. Intervalo de Confiança para $g(\mu)$

Com base na normalidade assintótica, podemos construir um intervalo de confiança aproximado para  $g(\mu)$ :

$$\hat{g} \pm z_{1-\alpha/2} \cdot \text{SE}(\hat{g})$$

No R:

```
# IC de 95% para  $g(\mu)$ 
lower <- g_hat - 1.96 * se_g_hat
upper <- g_hat + 1.96 * se_g_hat
c(lower, upper)
```

## 5. Resumo

- O estimador de máxima verossimilhança de  $g(\mu) = \Phi(\mu)$  é  $\hat{g} = \Phi(\bar{X})$ .
- A variância de  $\hat{g}$  pode ser aproximada via método delta e obtida no R com `deltamethod()`.
- Com essa variância, é possível construir intervalos de confiança para  $g(\mu)$ .